北京航空航天大學
SCHOOL OF SOFTWARE BEIHANG UNIVERSITY 软件学院

本科毕业设计（论文）开题报告

毕业设计题目：**基于 VLA 模型的机械臂多模态智能控制研究**

姓　　名：**高铭**

学　　号：**22373386**

学院指导老师：**王啸**

企业指导老师：**王静远**

企业老师单位：**北京航空航天大学计算机学院**

北京航空航天大学软件学院

2025 年 11 月 21 日

目　　录

1 论文背景与意义 1
1.1 选题来源与背景 1
1.2 选题意义 1
2 国内外研究现状分析 2
2.1 国外研究现状 2
2.1.1 从语言条件行为克隆到端到端 VLA 模型 2
2.1.2 动作生成：从自回归到流匹配生成 3
2.2 国内研究现状 5
2.3 现有研究存在的不足 6
3 研究目标和内容 6
3.1 研究目标 6
3.2 研究内容 6
4 总体方案和关键问题 9
4.1 拟采取的技术方案 9
4.2 关键问题/难点及解决思路 10
4.2.1 有限算力下的模型训练与显存优化 10
4.2.2 统一不同架构的评价指标 10
4.2.3 仿真向真机环境迁移的鸿沟 11
4.3 预期成果和可能创新点 11
5 论文工作计划 12
5.1 总体工作计划 12
5.2 本人工作内容 13
6 主要参考文献 13

1 论文背景与意义

1.1 选题来源与背景

本选题来源于教师命题，命题人为北京航空航天大学计算机学院王静远教授。

随着通用人工智能（AGI）研究的深入，具身智能（Embodied AI）已成为连接人工智能与物理世界的关键桥梁。传统的机器人控制方法高度依赖特定任务的数学建模，缺乏泛化能力。近年来，视觉-语言模型（VLM）通过结合视觉和语言获得了强大的多模态理解能力，催生了视觉-语言-动作（Vision-Language-Action, VLA）模型这一新兴范式。VLA 模型通过端到端的训练，使机器人能够理解自然语言指令并根据视觉感知直接输出控制信号。

然而，在 VLA 模型的发展过程中，关于动作空间表征与生成机制的研究出现了两个不同的主流流派，且尚未有定论。一类是以 OpenVLA[1]、RT-2[2]为代表的自回归（Auto regression）流派，其核心思想是将连续的物理动作离散化为文本 Token，利用大语言模型（LLM）强大的序列预测能力来生成动作；另一类是以π_0[3]为代表的连续生成（Continuous Generation）流派，该方法引入了流匹配（Flow Matching）或扩散模型（Diffusion）技术作为动作解码器，旨在保留动作的连续性与高频特性，以期获得更平滑的控制效果。

当前，针对这两类 VLA 架构在复杂多模态任务中的对比研究尚显匮乏。自回归方法是否损失了控制精度？基于流匹配的方法是否牺牲了语言推理能力？如何在有限的计算资源下验证这两种范式的优劣？此外，现有的 VLA 研究多集中于大规模集群训练，如何在有限算力下实现模型的有效微调与迁移？这些问题共同构成了本课题的研究背景。因此，开展基于 VLA 模型的机械臂多模态智能控制研究，对于推动具身智能的落地具有重要的研究价值。

1.2 选题意义

本研究拟在仿真环境及真机平台上，深入探究并对比基于不同动作生成范式的 VLA 模型，具有重要的理论与应用价值。

理论意义上，本研究将系统性地对比“自回归”与“流匹配”两种架构在多模态特征对齐、长序列任务推理以及动作平滑度方面的表现，为 VLA 模型的架构选型提供理论依据。此外，本文将通过在不同语义复杂度的指令下测试模型，分析 LLM 主干网络在不同动作解码策略下的语义留存情况，有助于理解语言能力如何更有效地转化为物理世界的操作能力。

现实意义上，本文的研究成果将有助于解决传统机械臂难以理解模糊指令的问题，通过 VLA 模型实现更自然的人机交互与更智能的自主决策。本文还将在消费级硬件上探索两种前沿模型的微调与部署方案，并尝试从仿真向真机的迁移（Sim2Real），这对于降低高性能具身智能机器人的研发门槛与落地成本具有显著的实际意义。

2 国内外研究现状分析

2.1 国外研究现状

2.1.1 从语言条件行为克隆到端到端 VLA 模型

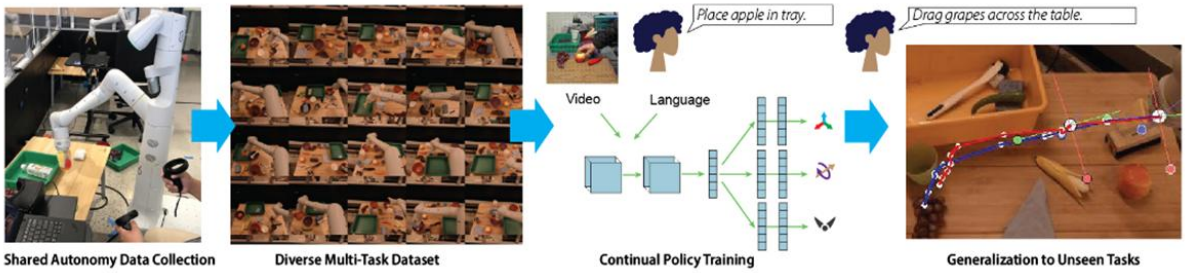

图 2.1 BC-Z 架构图

早期的机器人操作学习主要依赖于行为克隆（Behavior Cloning, BC），利用卷积神经网络（CNN）或 ResNet 处理视觉输入以预测动作。随着 CLIP[4]等视觉-语言预训练模型的出现，研究者开始尝试将语言指令作为条件嵌入到策略网络中，如 BC-Z[5]和 CLIPort[6]。然而，这类方法通常将语言和视觉作为独立的模态处理，未能充分利用大语言模型（LLM）深层的语义推理能力。

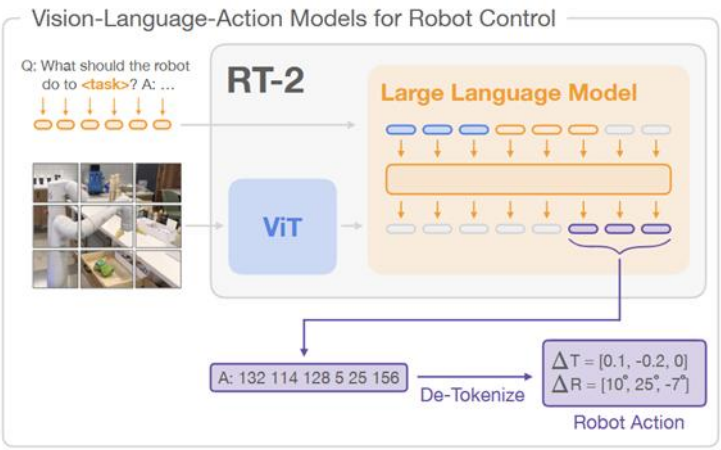

图 2.2 RT-2 架构图

为了解决这一问题，Google DeepMind 提出了 VLA（Vision-Language-Action）范式。RT-1[7]首先尝试利用 Transformer 架构处理多模态 Token，但仍保留了较为独立的视觉编码器。随后推出的 RT-2[2]则是一个里程碑式的工作，它通过协同微调直接将物理世界的动作转化为文本 Token，使得视觉-语言模型（VLM）具备了直接输出动作的能力，展现了涌现出的推理和泛化能力。

2.1.2 动作生成：从自回归到流匹配生成

随着 VLA 研究的深入，关于如何利用大模型解码生成高质量的机械臂动作，学术界形成了两个主要的研究流派，并均向着“连续化”与“高频化”演进：

1. 自回归流派。

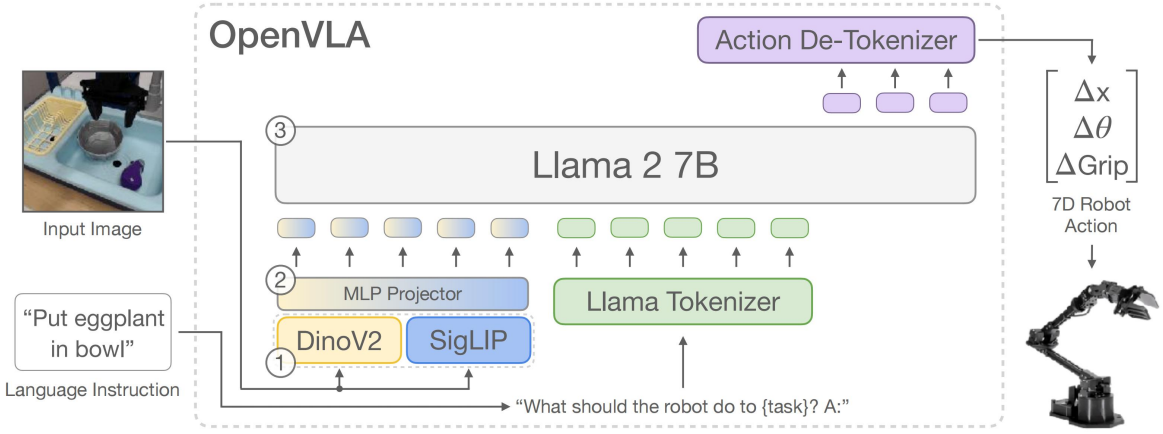

图 2.3 OpenVLA 架构图

这一流派以 RT-2[2]和斯坦福大学等机构开源的 OpenVLA[1]为代表。其核心思想是将

连续的机械臂动作离散化为有限的整数箱（Bins），并映射为词表中的 Token。其中 OpenVLA 使用 Llama-2 语言模型和 Prismatic 视觉编码器，采用典型的 Decoder-only 架构，将连续的机械臂关节角度或末端位姿离散化为 256 个整数区间，并在词表中对应为特殊的 Action Tokens，像生成文本一样逐个预测动作 Token。这种思想虽然能继承 LLM 在海量文本上学习到的逻辑推理和少样本学习能力，然而，离散化的动作必然导致精度损失，且自回归生成速度较慢，难以应对高频控制需求。OpenVLA 的自回归动作生成速率仅有 3-5Hz，无法满足 25-50Hz 的高频控制需要。

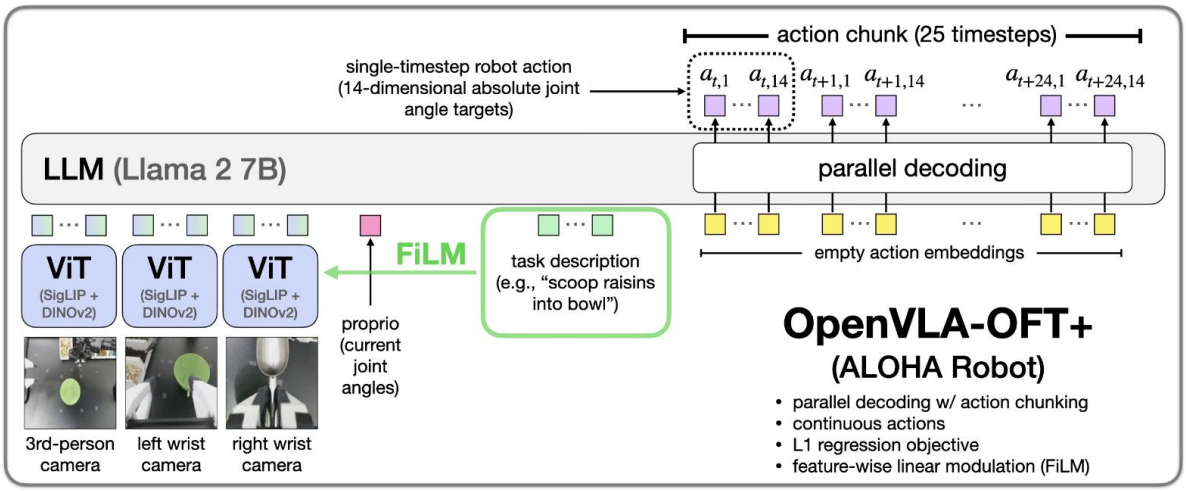

图 2.4 OpenVLA-OFT 架构图

为了突破这一瓶颈，近期的研究提出了 OpenVLA-OFT[8]等改进方案。OFT 引入了并行解码与连续动作表示，并结合了动作分块（Action Chunking）技术，使得模型能够一次性预测未来多个时间步的连续动作块，而非逐个预测离散 Token。这种改进既保留了 Transformer 的语义理解优势，又显著提升了控制的平滑度与推理帧率。

2. 流匹配流派。

为了从根本上解决动作生成的分布建模问题，另一类研究将生成式建模引入 VLA。早期的 Diffusion Policy[9]证明了迭代去噪过程在拟合多模态动作分布上的优越性，但在实现上没有充分融合语言特征，并非端到端的 VLA。

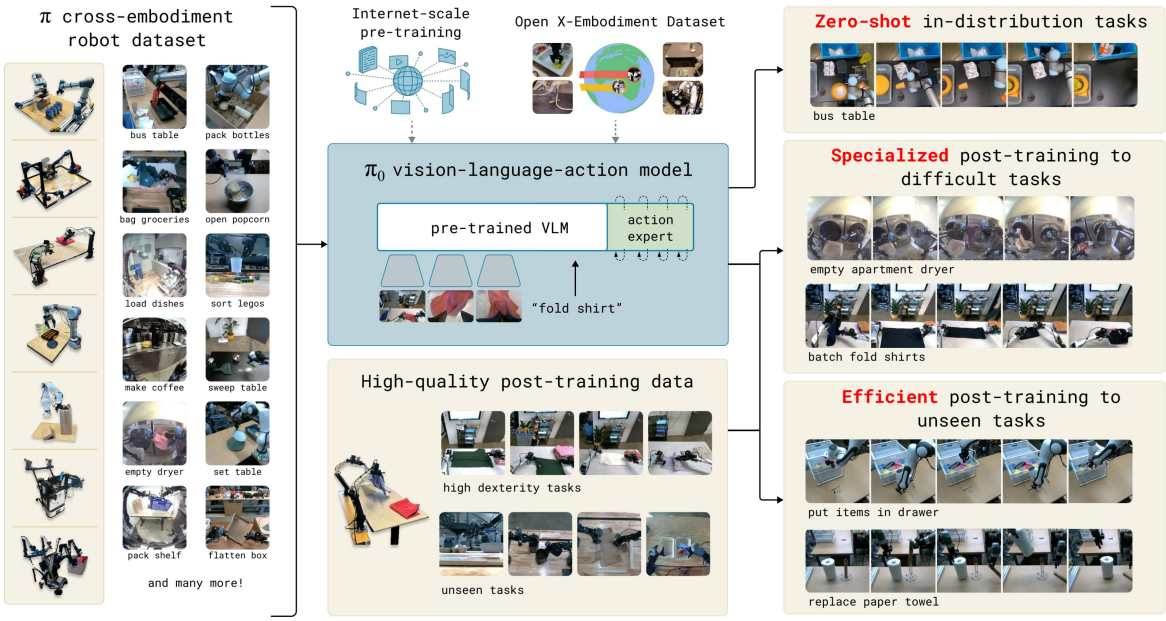

图 2.5 π_0 架构图

近期，Physical Intelligence 公司提出的π_0[3]以及后续的优化版本$\pi_{0.5}$模型[10]代表了该方向的最新进展。π_0结合了 VLM 的语义理解能力与流匹配的连续动作生成能力，引入动作专家机制，能够直接输出平滑、高精度的动作轨迹。这类方法在处理多模态分布时表现优异，更适合精细操作任务，并在长视距任务中表现出极佳的轨迹稳定性，正在成为新的研究热点，缺点是模型训练与评估的计算开销较大[11]。

2.2 国内研究现状

国内在具身智能领域的研究起步稍晚，但近年来发展迅速，主要集中在数据集构建、仿真环境开发及模型轻量化方面。

在仿真与基准测试方面，清华大学与德克萨斯大学奥斯汀分校合作推出的 LIBERO[12]基准，系统性地评估了具身智能模型的终身学习与知识迁移能力，成为当前 VLA 研究的重要测试平台。

在模型算法方面，国内银河通用、上海 AI lab 等企业和高校正在探索基于国产大模型（如通义千问、InternLM）的机械臂控制方案。例如，来自字节跳动、清华大学等的学者提出了 RoboFlamingo[13]，该模型在预训练 VLM 上通过查询转换器（Query Transformer）提取历史信息的架构，试图以较低的计算成本实现类似 RT-2 的效果。

此外，对 VLA 模型的轻量化、高效化研究也是国内的热点。华东师范大学和上海

AI Lab 的学者提出了 TinyVLA，通过使用鲁棒的高速多模态模型初始化策略主干，实现了更快的推理速度和更高的数据处理效率[14]。

2.3 现有研究存在的不足

通过对国内外研究现状的分析，可以发现当前 VLA 模型研究仍存在以下问题与不足。

架构对比研究的缺失：现有的文献大多单独提出一种基于自回归（如 OpenVLA-OFT）或基于流匹配（如π_0、$\pi_{0.5}$）的方法，缺乏在统一任务基准和相同硬件约束下，对这两种截然不同的动作解码范式进行系统性对比的研究。究竟是自回归架构在推理速度上的改进更重要，还是流匹配带来的动作平滑更关键，目前尚无定论。

计算资源门槛过高：主流 VLA 模型参数量巨大，即便在预训练模型基础上进行微调也往往需要 TPU 集群支持，普通的高校实验室难以复现。如何在消费级显卡上利用 LoRA 等技术实现高效微调，仍需进一步探索。

多模态指令的泛化验证不足：现有研究多关注简单的单步动作或任务指令，对于涉及空间推理、否定语义或长序列规划的复杂指令，VLA 模型的实际表现是否会有下降尚缺乏深入的实验验证。

这些未解决的问题正是本课题拟开展研究的切入点。本研究将致力于对比两种架构，并在受限算力下探索其性能边界。

3 研究目标和内容

3.1 研究目标

针对当前 VLA 模型在复杂语义指令下泛化能力未知的现状，本课题拟首先在 LIBERO 仿真基准上完成 OpenVLA-OFT 与 OpenPi 两大主流架构的复现与性能基准测试；进而利用大模型 Agent 构建语义增强的指令数据集，通过参数高效微调（LoRA）技术使模型适应复杂指令场景；最终系统性地对比自回归与流匹配两种架构在处理高难度语义任务时的性能差异，并探索控制策略从仿真向真机迁移的可行性。

3.2 研究内容

为了达到上述研究目标，本论文将重点开展以下几方面的工作：

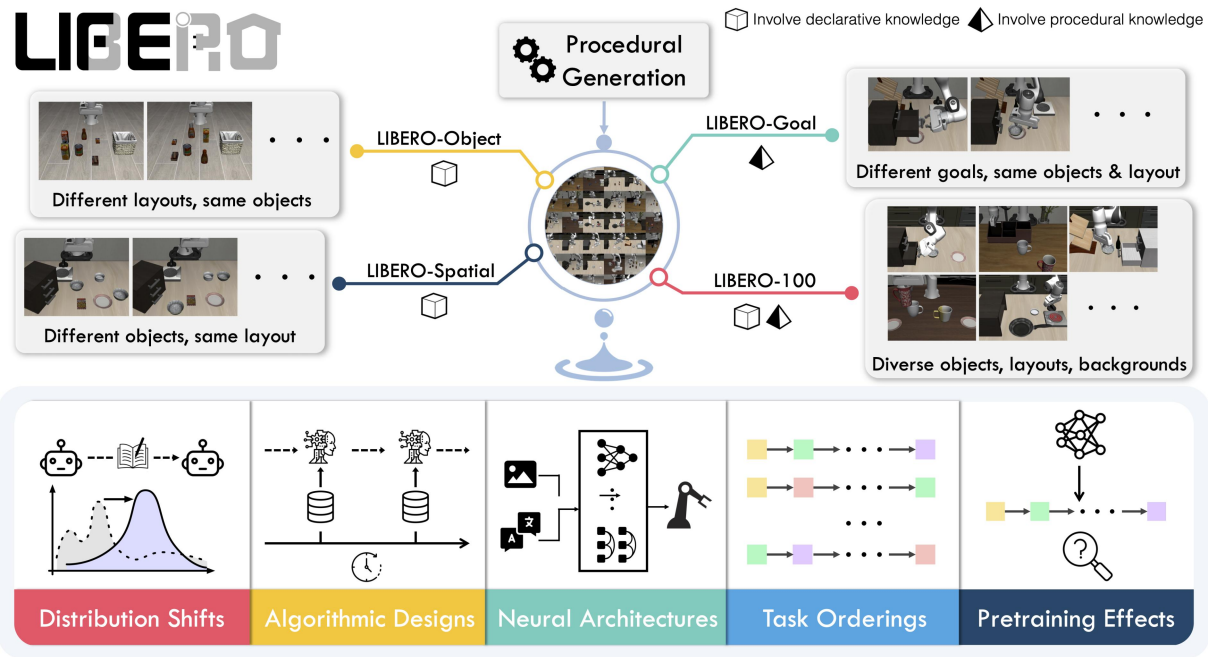

图 3.1 LIBERO 介绍图

(1) VLA 模型在 LIBERO 基准上的复现与基线确立

作为研究的起点，本研究将首先在双卡 RTX 3090 计算平台上，完成 OpenVLA-OFT（自回归架构）与 OpenPi（流匹配架构）在 LIBERO（Lifetime Benchmarks for Robot Manipulation）仿真环境中的环境部署。通过运行 LIBERO-Object、LIBERO-Goal、LIBERO-Spatial 和 LIBERO-90 等标准任务套件，记录两个模型在原始指令集下的成功率、推理速度及显存占用情况，建立后续对比实验的 Baseline，并验证官方提供的微调脚本在本地环境的可运行性。

(2) 基于大模型 Agent 的 LIBERO 指令集语义增强

为了探究模型在非结构化指令下的泛化边界，本研究不局限于 LIBERO 原始的简单模板指令（如“拾起方块”），而是对原版套件中的 prompt 描述进行泛化性修改。我将借助大模型 Agent 对原始任务描述进行语义重构与扩展，生成包含同义改写、否定约束及模糊指代的多样化指令集（如将“打开抽屉”改写为“拉开那个把手是红色的储物格”）。该部分工作旨在构建一个更高难度的“语义增强版 LIBERO 数据集”，为后续的模型训练与评估提供数据支撑。

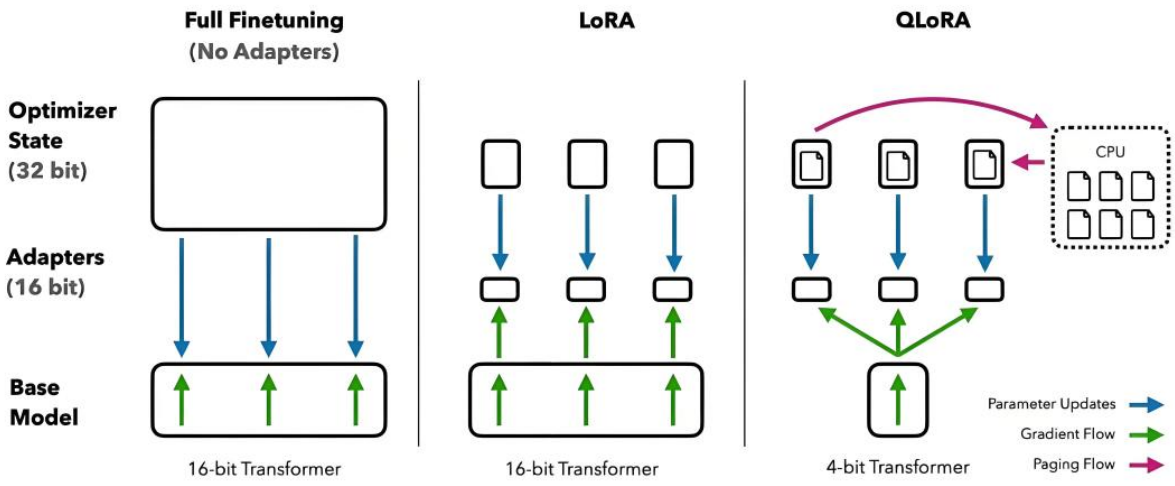

图 3.2 全量微调、LoRA 与 QLoRA 对比图

(3) 基于 LoRA 的 VLA 模型高效微调适配

针对增强后的多模态数据集，本研究将利用官方仓库提供的微调接口，采用 LoRA (Low-Rank Adaptation) 技术和量化技术（Quantization）对 OpenVLA-OFT 和 OpenPi 进行参数高效微调（PEFT, Parameter-Efficient Fine-Tuning）。研究将重点探究在保持预训练权重大部分冻结的情况下，仅更新少量秩参数是否足以让模型掌握复杂的语义逻辑。此过程将记录 Loss 收敛曲线，并对比两种不同架构在面对相同规模的新增语义数据时，其训练效率与收敛速度的差异。

(4) 增强语义场景下的架构性能对比

这是本论文的分析部分。研究将使用微调后的两个模型在“语义增强版 LIBERO”任务中进行测试，并与原版 LIBERO 的基线性能进行对比。计划回答如下问题：1、语义理解能力方面，OpenVLA-OFT 的自回归架构是否在处理逻辑推理指令时优于连续流匹配架构？2、动作执行质量方面，π_0 的连续动作生成是否在长序列任务中表现出更好的轨迹平滑度与抗干扰性？此外计划进行消融实验，分析指令复杂度的增加对模型成功率的具体影响幅度。

图 3.3 松灵 PiPER 机械臂示意图

(5) 基于 PiPER 机械臂的真机迁移验证（选做）

为了验证模型在真实物理世界中的有效性，本研究将搭建基于松灵 PiPER 机械臂的真机实验平台。首先，通过遥操作方式在真实桌面场景下采集少量的专家演示数据，包含视觉观测与动作轨迹。随后，不再仅依赖仿真策略的直接迁移，而是直接利用这些真机数据对 OpenVLA-OFT 和 OpenPi 的预训练基础模型进行微调，以消除仿真与真机之间的视觉域差异。最后，在真机上实时运行微调后的模型，对比两个架构在真实环境下的推理速度、动作平滑度及任务成功率。

4 总体方案和关键问题

4.1 拟采取的技术方案

本论文拟采取“仿真基准复现—语义数据增强—模型高效微调—架构对比评估—真机场景验证”的技术路线。整个技术体系自下而上紧密衔接：底层依托 LIBERO 仿真平台构建标准化的操作任务环境，并利用实验室现有的 RTX 3090 工作站与松灵 PiPER 机械臂提供算力与硬件支持；数据层将通过引入大语言模型智能体，对仿真环境中的原始指令进行语义重构与逻辑扩展，构建具有高泛化难度的增强型数据集；算法层将重点部署并对比两类前沿架构——基于自回归 Transformer 的 OpenVLA-OFT 模型与基于流匹配机制的 OpenPi 模型；应用层则致力于探索从仿真策略到真机控制的迁移验证，最终形成一套完整的 VLA 控制系统。

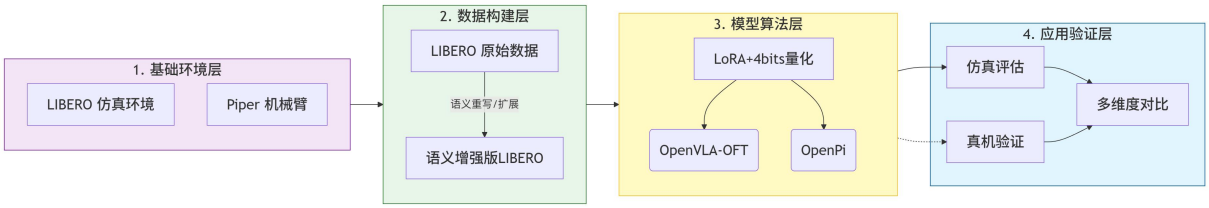

图 4.1 本研究技术体系示意图

在仿真环境构建与数据扩展方面，本研究首先将基于 MuJoCo 部署 LIBERO 基准套件，首先重点复现 LIBERO-Spatial 和 LIBERO-Long 等任务，以确保整体实验链路稳定可用，随后进行四套任务的扩展。针对原始任务指令较为单一的问题，计划设计一套自动化指令扩展流程，利用大型语言模型生成更具多样性的描述，包括同义表达、否定型约束（如“避免触碰红色物体”）以及更细致的空间定位表达（如“拉开最左侧抽屉”）。

最终形成由图像、扩展指令与动作轨迹构成的训练样本，为后续模型泛化能力的评估提供更丰富的数据基础。

在模型部署与复现方面，本研究将分别搭建 OpenVLA-OFT 与 OpenPi 环境并获得预训练基础模型。对于 OpenVLA-OFT，将重点验证其连续动作头与动作分块机制在推理速度与动作平滑度上的改进；对于 OpenPi，则将复现其基于流匹配的生成方式，考察其在处理复杂多模态分布时的表现。以上模型均将在同一 GPU 环境中完成推理配置和基线测试，为后续实验建立可靠参照。

在微调与真机迁移阶段，本研究将结合消费级显卡的限制，采用参数高效微调策略。针对 OpenVLA-OFT，将基于 LoRA 或其官方高效微调接口，在冻结 Llama 主干参数的前提下，仅更新少量适配器权重，以适应扩展后的指令数据。对于 OpenPi，将探索在特定层进行微调或采用轻量化训练的方案。除了 LoRA，也可以尝试 4bits 量化等方式进一步降低模型复杂度。在真机验证中，将通过 ROS2 接口与 PiPER 机械臂完成对接，在真实场景下采集约 50 条专家示范数据，分别在两个模型上进行微调并评估结果。

4.2 关键问题/难点及解决思路

4.2.1 有限算力下的模型训练与显存优化

OpenVLA-OFT 与 OpenPi 均属于参数量巨大的深度神经网络，全量微调通常需要 A100 集群级别的算力支持，而实验室显存资源相对受限，这是本文面临的首要工程难题。针对这一问题，本研究将主要采用量化与高效微调技术相结合的解决思路。一方面，利用 bitsandbytes 库将模型主干以 4-bit 或 8-bit 精度加载，大幅压缩显存占用；另一方面，严格限制可训练参数的规模，主要采用 LoRA 技术，仅在 Transformer 的 Attention 层或 MLP 层插入低秩矩阵进行更新，确保训练过程中的梯度显存占用控制在 24GB 以内。此外，还将利用梯度检查点技术，以微小的计算时间代价换取显著的显存空间释放，从而支持更大的 Batch Size 训练。

4.2.2 统一不同架构的评价指标

本课题的核心在于对比 OpenVLA-OFT 与 OpenPi 两种截然不同的架构。前者基于自回归 Transformer 主干，通过解码头输出连续动作块；后者则基于流匹配生成模型，通

过迭代去噪生成动作轨迹。两者的训练目标函数、推理延时机制及对数据的敏感度均存在本质差异。此外，两个模型的微调均基于 LIBERO 数据集，那么该如何构建测试集以防止过拟合？因此，如何设计公平的对比实验是一个理论难点。为此，本研究将建立统一的评估基准：首先，严格控制训练数据的一致性，确保两者均在相同的“语义增强版 LIBERO”数据集上进行微调，这样增加了测试的难度，更能体现 VLA 模型在语义泛化性上的表现如何；其次，在评价指标上，不仅关注最终的任务成功率，还将引入能够反映动作质量的“轨迹平滑度”、反映模型效率的“推理延迟”以及反映语义理解的“指令完成度”等多维指标。通过控制变量法，深入分析不同架构在处理逻辑推理指令与精细操作任务时的各自优势。

4.2.3 仿真向真机环境迁移的鸿沟

仿真环境中的渲染图像与真实物理世界的摄像头画面在光照、纹理及阴影上存在显著的视觉域差异，且真实机械臂的动力学特性与仿真模型难以完全一致，直接部署往往导致成功率骤降。为了解决这一 Sim-to-Real 的难题，本研究将放弃“零样本直接迁移”的方案，转而采用“真机数据微调”的稳健策略。在仿真训练完成后，通过遥操作在真机上采集包含真实图像与 PiPER 关节状态的少量数据集，对模型进行最后一轮的适应性微调。同时，在仿真训练阶段引入域随机化（Domain Randomization）技术，随机调整仿真环境的光照强度与纹理贴图，预先提升模型对视觉干扰的鲁棒性。在真机测试时对测试场景进行光照、场景布局、环境等的泛化，避免过拟合对两模型评估造成的影响。

4.3 预期成果和可能创新点

通过本课题的研究，预期将形成一系列具有学术价值与工程应用价值的成果。首先，将撰写一篇逻辑严密、数据详实的本科学位论文，字数预计 2-3 万字。其次，将基于相关开源成果产出一套完整的 VLA 机械臂控制代码库，涵盖基于 LIBERO 的环境配置、自动化指令增强脚本、OpenVLA-OFT 与 OpenPi 的高效微调脚本以及适配 PiPER 机械臂的真机推理接口。此外，还将构建并开源一份“语义增强版 LIBERO 数据集”，为社区提供富含复杂逻辑指令的训练样本。最终，将录制包含仿真与真机环境的演示视频，直观展示机械臂在模糊或推理型指令下完成操作任务的全过程。

本课题可能的创新点在于系统性地揭示了自回归架构与流匹配架构在复杂语义具身任务中的性能边界。不同于现有研究仅关注单一模型的性能指标，本研究在统一的语义增强基准下，深入对比了 OpenVLA-OFT 与 OpenPi 在处理逻辑推理与长序列操作时的行为差异，验证了结合 LLM 语义推理优势与流匹配动作生成优势的必要性，为未来具身智能模型的架构融合与选型提供了重要的实验依据。

5 论文工作计划

5.1 总体工作计划

本工作的研究周期预计为 5 个月，具体阶段划分及主要工作内容安排如下：

阶段	时间安排	主要工作内容	预期产出
第一阶段：调研与准备	2025.11.01 - 2025.11.30	1. 查阅国内外关于 VLA 模型、自回归及流匹配生成的文献。	文献综述
		2. 熟悉 LIBERO 仿真环境及 OpenVLA-OFT、OpenPi 的代码架构。	开题报告
		3. 撰写开题报告，明确技术路线。	
第二阶段：基线复现	2025.12.01 - 2025.12.31	1. 部署 LIBERO 仿真环境。	
		2. 完成 OpenVLA-OFT 与 OpenPi 的权重加载与推理测试。	基线性能测试报告
		3. 跑通 LIBERO-Spatial 和 LIBERO-Long 任务套件，记录原始模型的基线数据。	
第三阶段：方法设计与实现	2026.01.01 - 2026.02.28	1. 数据增强：开发 LLM Agent 脚本，对 LIBERO 指令进行语义重写与扩展，构建增强数据集。	语义增强数据集
		2. 模型微调：搭建 LoRA 高效微调流水线，分别对两个模型进行适配训练。	微调后的模型权重
第四阶段：对比实验与真机	2026.03.01 - 2026.04.01	1. 对比评估：在仿真中系统测试两种架构在复杂指令下的成功率与动作质量。	
		2. 真机迁移：搭建机械臂实验台，采集真机数据，进行 Sim-to-Real 微调与验证。	真机演示 Demo 视频

		3. 整理实验数据，绘制图表。	实验数据对比图表
第五阶段：论文撰写与答辩	2026.04.01 - 答辩日	1. 撰写毕业论文初稿，完成中期检查。	毕业论文终稿
		2. 根据导师意见修改论文，定稿及查重。	答辩 PPT
		3. 制作答辩 PPT，准备答辩演示材料。	

5.2 本人工作内容

本课题为个人独立完成的研究项目。本人作为项目的唯一执行人，独立承担了从选题调研、方案设计、系统实现到实验验证的全部工作。

6 主要参考文献

[1] KIM M J, PERTSCH K, KARAMCHETI S, 等. OpenVLA: An Open-Source Vision-Language-Action Model[A/OL]. arXiv, 2024[2025-10-11]. http://arxiv.org/abs/2406.09246. DOI:10.48550/arXiv.2406.09246.

[2] BROHAN A, BROWN N, CARBAJAL J, 等. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[A/OL]. arXiv, 2023[2025-10-09]. http://arxiv.org/abs/2307.15818. DOI:10.48550/arXiv.2307.15818.

[3] BLACK K, BROWN N, DRIESS D, 等. $π_0$: A Vision-Language-Action Flow Model for General Robot Control[A/OL]. arXiv, 2024[2025-10-11]. http://arxiv.org/abs/2410.24164. DOI:10.48550/arXiv.2410.24164.

[4] RADFORD A, KIM J W, HALLACY C, 等. Learning Transferable Visual Models From Natural Language Supervision[A/OL]. arXiv, 2021[2025-11-19]. http://arxiv.org/abs/2103.00020. DOI:10.48550/arXiv.2103.00020.

[5] JANG E, IRPAN A, KHANSARI M, 等. BC-Z: Zero-Shot Task Generalization with Robotic Imitation Learning[A/OL]. arXiv, 2022[2025-11-19]. http://arxiv.org/abs/2202.02005. DOI:10.48550/arXiv.2202.02005.

[6] SHRIDHAR M, MANUELLI L, FOX D. CLIPort: What and Where Pathways for Robotic Manipulation[A/OL]. arXiv, 2021[2025-10-10]. http://arxiv.org/abs/2109.12098.

DOI:10.48550/arXiv.2109.12098.

[7] BROHAN A, BROWN N, CARBAJAL J, 等. RT-1: Robotics Transformer for Real-World Control at Scale[A/OL]. arXiv, 2023[2025-10-11]. http://arxiv.org/abs/2212.06817. DOI:10.48550/arXiv.2212.06817.

[8] KIM M J, FINN C, LIANG P. Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success[A/OL]. arXiv, 2025[2025-10-13]. http://arxiv.org/abs/2502.19645. DOI:10.48550/arXiv.2502.19645.

[9] CHI C, XU Z, FENG S, 等. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion[A/OL]. arXiv, 2024[2025-10-09]. http://arxiv.org/abs/2303.04137. DOI:10.48550/arXiv.2303.04137.

[10] INTELLIGENCE P, BLACK K, BROWN N, 等. $π_{0.5}$: a Vision-Language-Action Model with Open-World Generalization[A/OL]. arXiv, 2025[2025-10-14]. http://arxiv.org/abs/2504.16054. DOI:10.48550/arXiv.2504.16054.

[11] KAWAHARAZUKA K, OH J, YAMADA J, 等. Vision-Language-Action Models for Robotics: A Review Towards Real-World Applications[A/OL]. (2025-10-08)[2025-10-13]. http://arxiv.org/abs/2510.07077. DOI:10.1109/ACCESS.2025.3609980.

[12] LIU B, ZHU Y, GAO C, 等. LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning[A/OL]. arXiv, 2023[2025-10-10]. http://arxiv.org/abs/2306.03310. DOI:10.48550/arXiv.2306.03310.

[13] LI X, LIU M, ZHANG H, 等. Vision-Language Foundation Models as Effective Robot Imitators[A/OL]. arXiv, 2024[2025-11-19]. http://arxiv.org/abs/2311.01378. DOI:10.48550/arXiv.2311.01378.

[14] WEN J, ZHU Y, LI J, 等. TinyVLA: Towards Fast, Data-Efficient Vision-Language-Action Models for Robotic Manipulation[A/OL]. arXiv, 2025[2025-11-04]. http://arxiv.org/abs/2409.12514. DOI:10.48550/arXiv.2409.12514.